

Reporte Técnico de Ingeniería

Práctica Integral — Caso 1: Adquisición de Medicamentos a Demanda

Asignatura: Extracción de Conocimiento en Bases de Datos (Unidad II)

Programa: Ingeniería en Gestión de Desarrollo de Software (UTEQ)

Docente: BRANDON EFREN VENEGAS OLVERA

Equipo: 1

Autores: Marco Antonio Gómez Olvera, Orlando Rubio Cabrera, Sandra Zoe Cabrera Velazquez, Israel Gómez Bonilla

Dataset: INPRFM — Adquisición de medicamentos demanda (2025)

Fuente: datos.gob.mx

1. Fase Documental y Justificación

El dataset crudo proviene del Instituto Nacional de Psiquiatría Ramón de la Fuente Muñiz (INPRFM) y contiene **2,171 registros** de adquisiciones de medicamentos del año 2025. El diagnóstico inicial reveló las siguientes imperfecciones de origen:

Encoding inconsistente: el archivo viene en latin-1 con caracteres corruptos en acentos. **Formatos de fecha no estándar:** dd/mm/yyyy en lugar de ISO 8601. **Montos con comas separadoras de miles:** requieren normalización a tipo flotante. **Espacios múltiples y mayúsculas inconsistentes:** en nombres de proveedores y medicamentos.

Dado que todas las transacciones del dataset son del tipo *Adjudicación Directa* y el origen de recursos es uniforme (*Recursos Federales Ramo 12*), se diseñó una **variable target predictiva alternativa** con sentido de negocio: `target_costo_alto`, que clasifica como positiva (1) toda adquisición cuyo monto total supere el **percentil 75** (1.81), permitiendo identificar compras anómalamente costosas para auditoría preventiva.

2. Mapeo de Procesos E-T-L (Pandas)

El pipeline de limpieza y transformación se implementó en un notebook de Jupyter con Pandas, aplicando las siguientes reglas de negocio:

Regla	Implementación Técnica
Limpieza Regex	<code>str.replace(r'\s+ , ,')</code> + eliminación de caracteres no alfanuméricos + homologación a MA
Normalización de fechas	<code>pd.to_datetime(format=%d/%m/%Y)</code> a tipo DATE ISO 8601
Tipado numérico	Conversión de comas a punto decimal con <code>float(str.replace(,,).strip())</code>
Variable target	<code>target_costo_alto = (total > p75).astype(int)</code> donde <code>p75 = .81</code>
Surrogate Keys	Autoincrementales por dimensión (<code>sk</code>) generadas con <code>range(1, n+1)</code>

3. Evidencias del Pipeline y Modelado

La descomposición de la tabla plana generó **5 dimensiones** y **1 tabla de hechos**, respetando el esquema estrella Kimball:

dim_tiempo: 219 registros únicos de fecha.**dim_medicamento:** 375 combinaciones únicas de nombre, sustancia, forma, concentración y presentación.**dim_proveedor:** 61 proveedores distintos con RFC normalizado.**dim_institucion:** 1 institución (CLUES único del INPRFM).**dim_contratacion:** 1 tipo de adquisición + 1 origen de recurso.**fct_adquisiciones:** 2,171 hechos con medidas numéricas y target binario.

4. Validación de Archivos Analíticos

El particionamiento Train/Test se generó con `train_test_split(..., test_size=0.25, stratify=y, random_state=42)`. La validación confirma que la proporción del target se conserva idéntica en ambos conjuntos:

Conjunto	Registros	Clase 0 (Costo normal)	Clase 1 (Costo alto)
Origen (100%)	2171	75.1%	24.9%
Entrenamiento (75%)	1628	75.1%	24.9%
Prueba (25%)	543	75.1%	24.9%

5. Esquema Estrella en PostgreSQL

El motor PostgreSQL 17 aloja el esquema `ecbd_caso1` con las siguientes características de diseño:

Llaves foráneas desde `fct_adquisiciones` hacia las 5 dimensiones.**Índices analíticos** sobre `tiempo_sk`, `medicamento_sk`, `proveedor_sk` y `contratacion_sk` para acelerar agregaciones.**Restricciones de dominio:** `CHECK (cantidad >= 0)`, `CHECK (target_costo_alto IN (0,1))`.**Columnas generadas:** `nombre_mes` derivado automáticamente del número de mes.

6. Conclusión

La práctica integral demostró la capacidad de procesar datos reales del Gobierno Federal con imperfecciones estructurales, aplicar limpieza avanzada con expresiones regulares, modelar dimensionalmente bajo el estándar Kimball y generar datasets balanceados para la fase posterior de minería de datos. El target `target_costo_alto` ofrece un problema de clasificación binaria realista (75/25) que servirá como insumo para las unidades siguientes de Regresión Logística, Árboles de Decisión y Random Forest.