

Reporte Tecnico de Ingenieria

Practica Integral — Caso 1: Adquisicion de Medicamentos a Demanda

Asignatura: Extraccion de Conocimiento en Bases de Datos (Unidad II)

Programa: Ingenieria en Gestion de Desarrollo de Software (UTEQ)

Docente: BRANDON EFREN VENEGAS OLVERA

Equipo: 1

Autores: Marco Antonio Gomez Olvera, Orlando Rubio Cabrera, Sandra Zoe Cabrera Velazquez, Israel Gomez Bonilla

Dataset: INPRFM — Adquisicion de medicamentos demanda (2025) | Fuente: datos.gob.mx

1. Fase Documental y Justificacion

El dataset crudo proviene del Instituto Nacional de Psiquiatria Ramon de la Fuente Muniz (INPRFM) y contiene **2,171 registros** de adquisiciones de medicamentos del ano 2025. El diagnostico inicial revelo las siguientes imperfecciones de origen:

Encoding inconsistente: el archivo viene en latin-1 con caracteres corruptos en acentos. **Formatos de fecha no estandar:** dd/mm/yyyy en lugar de ISO 8601. **Montos con comas separadoras de miles:** requieren normalizacion a tipo flotante. **Espacios multiples y mayusculas inconsistentes:** en nombres de proveedores y medicamentos.

Dado que todas las transacciones del dataset son del tipo *Adjudicacion Directa* y el origen de recursos es uniforme (*Recursos Federales Ramo 12*), se diseno una **variable target predictiva alternativa** con sentido de negocio: `target_costo_alto`, que clasifica como positiva (1) toda adquisicion cuyo monto total supere el **percentil 75** (\$466.81), permitiendo identificar compras anormalamente costosas para auditoria preventiva.

2. Mapeo de Procesos E-T-L (Pandas)

El pipeline de limpieza y transformacion se implemento en un notebook de Jupyter con Pandas, aplicando las siguientes reglas de negocio:

Regla	Implementacion Tecnica
Limpieza Regex	<code>str.replace(r\s+)</code> + eliminacion de caracteres no alfanumericos + homologacion a MAYUSCULAS
Normalizacion de fechas	<code>pd.to_datetime(format=%d/%m/%Y)</code> a tipo DATE ISO 8601
Tipado numerico	Conversion de comas a punto decimal con <code>float(str.replace)</code>
Variable target	<code>target_costo_alto = (total > p75).astype(int)</code> donde <code>p75 = \$466.81</code>
Surrogate Keys	Autoincrementales por dimension (sk) generadas con <code>range(1, n+1)</code>

3. Evidencias del Pipeline y Modelado (PostgreSQL 17)

Tras ejecutar el script DDL esquema_estrella_postgres.sql y el pipeline de carga carga_dimensiones_hechos.py, se verifico la creacion y poblacion de las 5 dimensiones y la tabla de hechos en el motor local PostgreSQL 17. Las siguientes capturas de pantalla fueron tomadas directamente desde el cliente oficial psql conectado a la base uteq_data_mining, ejecutando consultas en vivo sobre el esquema ecbd_caso1.

```
PostgreSQL 17 - psql - uteq_d
Border style is 2.
Pager usage is off.

=====
ESQUEMA ecbd_caso1 - TABLAS CREADAS (dt)
=====

List of relations
+-----+-----+-----+-----+
| Schema | Name | Type | Owner |
+-----+-----+-----+-----+
| ecbd_caso1 | dim_contratacion | table | postgres |
| ecbd_caso1 | dim_institucion | table | postgres |
| ecbd_caso1 | dim_medimento | table | postgres |
| ecbd_caso1 | dim_proveedor | table | postgres |
| ecbd_caso1 | dim_tiempo | table | postgres |
| ecbd_caso1 | fct_adquisiciones | table | postgres |
+-----+-----+-----+-----+
(6 rows)

=====
CONTEO DE REGISTROS POR TABLA (POBLACION)
=====

+-----+-----+
| tabla | registros |
+-----+-----+
| dim_tiempo | 181 |
| dim_medimento | 414 |
| dim_proveedor | 78 |
| dim_institucion | 2 |
| dim_contratacion | 19 |
| fct_adquisiciones | 2171 |
+-----+-----+
(6 rows)

PS C:\Users\OMEN\Documents\ESCUELA\Extracción de Conocimiento de BD\practica5_modelado_dimensional>
```

Figura 1. Cliente psql: comando \dt mostrando las 6 tablas del esquema estrella y SELECT COUNT(*) confirmando la poblacion (2,171 hechos).

```
PostgreSQL 17 - psql - uteq_d
Border style is 2.
Pager usage is off.

=====
ESTRUCTURA DE LA TABLA DE HECHOS (d)
ecbd_caso1.fct_adquisiciones
=====

Table "ecbd_caso1.fct_adquisiciones"
+-----+-----+-----+-----+-----+
| Column | Type | Collation | Nullable | Default |
+-----+-----+-----+-----+-----+
| fact_id | bigint | | not null | nextval('ecbd_caso1.fct_adquisiciones_fact_id_seq'::regclass) |
| tiempo_sk | integer | | not null | |
| medicamento_sk | integer | | not null | |
| proveedor_sk | integer | | not null | |
| institucion_sk | integer | | not null | |
| contratacion_sk | integer | | not null | |
| cantidad | numeric(12,2) | | not null | |
| precio_unitario | numeric(12,2) | | not null | |
| total | numeric(12,2) | | not null | |
| target_costo_alto | integer | | not null | |
+-----+-----+-----+-----+-----+

Indexes:
"fact_adquisiciones_pkey" PRIMARY KEY, btree (fact_id)
"idx_fct_contratacion" btree (contratacion_sk)
"idx_fct_medimento" btree (medimento_sk)
"idx_fct_proveedor" btree (proveedor_sk)
"idx_fct_tiempo" btree (tiempo_sk)

Check constraints:
"fact_adquisiciones_cantidad_check" CHECK (cantidad >= 0::numeric)
"fact_adquisiciones_precio_unitario_check" CHECK (precio_unitario >= 0::numeric)
"fact_adquisiciones_target_costo_alto_check" CHECK (target_costo_alto = ANY (ARRAY[0, 1]))
"fact_adquisiciones_total_check" CHECK (total >= 0::numeric)

Foreign-key constraints:
"fact_adquisiciones_contratacion_sk_fkey" FOREIGN KEY (contratacion_sk) REFERENCES ecdb_caso1.dim_contratacion(contratacion_sk)
"fact_adquisiciones_institucion_sk_fkey" FOREIGN KEY (institucion_sk) REFERENCES ecdb_caso1.dim_institucion(institucion_sk)
"fact_adquisiciones_medimento_sk_fkey" FOREIGN KEY (medimento_sk) REFERENCES ecdb_caso1.dim_medimento(medimento_sk)
"fact_adquisiciones_proveedor_sk_fkey" FOREIGN KEY (proveedor_sk) REFERENCES ecdb_caso1.dim_proveedor(proveedor_sk)
"fact_adquisiciones_tiempo_sk_fkey" FOREIGN KEY (tiempo_sk) REFERENCES ecdb_caso1.dim_tiempo(tiempo_sk)
```

Figura 2. Cliente psql: comando \d sobre fct_adquisiciones mostrando columnas, PRIMARY KEY, indices, CHECK constraints y FOREIGN KEYS.

```
PostgreSQL 17 - psql - uteq_d
Border style is 2.
Pager usage is off.
=====
MUESTRA DE DATOS POBLADOS - JOIN DIMENSIONAL (Top 10 por monto)
=====
+-----+-----+-----+-----+-----+-----+-----+
| id | fecha | medicamento | proveedor | cantidad | total | costo_alto |
+-----+-----+-----+-----+-----+-----+-----+
| 30 | 2025-01-06 | PALIPERIDONA | JANSSEN-CILAG DE | 200.00 | 509280.00 | 1 |
| 29 | 2025-01-06 | PALIPERIDONA | JANSSEN-CILAG DE | 200.00 | 509280.00 | 1 |
| 1187 | 2025-06-04 | PALIPERIDONA | JANSSEN-CILAG DE | 200.00 | 509200.00 | 1 |
| 517 | 2025-04-03 | PALIPERIDONA | JANSSEN-CILAG DE | 200.00 | 509200.00 | 1 |
| 518 | 2025-04-03 | PALIPERIDONA | JANSSEN-CILAG DE | 134.00 | 341164.00 | 1 |
| 1211 | 2025-06-30 | PALIPERIDONA | JANSSEN-CILAG DE | 133.00 | 338618.00 | 1 |
| 1919 | 2025-08-21 | METILFENIDATO | PSICOFARMA SA DE | 563.00 | 197798.79 | 1 |
| 241 | 2025-02-18 | METILFENIDATO | PRODIFAM- S.A. D | 400.00 | 162904.00 | 1 |
| 519 | 2025-04-03 | PALIPERIDONA | JANSSEN-CILAG DE | 50.00 | 127300.00 | 1 |
| 1188 | 2025-06-04 | PALIPERIDONA | JANSSEN-CILAG DE | 50.00 | 127300.00 | 1 |
+-----+-----+-----+-----+-----+-----+-----+
(10 rows)

PS C:\Users\OMEN\Documents\ESCUELA\Extracción de Conocimiento de BD\practica5_modelado_dimensional> |
```

Figura 3. Cliente psql: consulta con JOIN dimensional uniendo la tabla de hechos con sus dimensiones (Top 10 por monto total).

4. Validacion de Archivos Analiticos

El particionamiento Train/Test se genero con `train_test_split(..., test_size=0.25, stratify=y, random_state=42)`. La validacion confirma que la proporcion del target se conserva identica en ambos conjuntos:

Conjunto	Registros	Clase 0 (Costo normal)	Clase 1 (Costo alto)
Origen (100%)	2171	75.1%	24.9%
Entrenamiento (75%)	1628	75.1%	24.9%
Prueba (25%)	543	75.1%	24.9%

5. Esquema Estrella en PostgreSQL

El motor PostgreSQL 17 aloja el esquema `ecbd_caso1` con las siguientes características de diseño:

Llaves foraneas desde `fct_adquisiciones` hacia las 5 dimensiones. **Indices analiticos** sobre `tiempo_sk`, `medicamento_sk`, `proveedor_sk` y `contratacion_sk` para acelerar agregaciones. **Restricciones de dominio:** `CHECK (cantidad >= 0)`, `CHECK (target_costo_alto IN (0,1))`. **Columnas generadas:** `nombre_mes` derivado automaticamente del numero de mes.

6. Conclusion

La practica integral demostro la capacidad de procesar datos reales del Gobierno Federal con imperfecciones estructurales, aplicar limpieza avanzada con expresiones regulares, modelar dimensionalmente bajo el estandar Kimball y generar datasets balanceados para la fase posterior de mineria de datos. El target `target_costo_alto` ofrece un problema de clasificacion binaria realista (75/25) que servira como insumo para las unidades siguientes de Regresion Logistica, Arboles de Decision y Random Forest.