

Reporte Tecnico de Ingenieria

Practica Integral — Caso 1: Adquisicion de Medicamentos a Demanda

Asignatura: Extraccion de Conocimiento en Bases de Datos (Unidad II)

Programa: Ingenieria en Gestion de Desarrollo de Software (UTEQ)

Docente: BRANDON EFREN VENEGAS OLVERA

Equipo: 1

Autores: Marco Antonio Gomez Olvera, Orlando Rubio Cabrera, Sandra Zoe Cabrera Velazquez, Israel Gomez Bonilla

Dataset: INPRFM — Adquisicion de medicamentos demanda (2025) | Fuente: datos.gob.mx

1. Fase Documental y Justificacion

El dataset crudo proviene del Instituto Nacional de Psiquiatria Ramon de la Fuente Muniz (INPRFM) y contiene **2,171 registros** de adquisiciones de medicamentos del ano 2025. El diagnostico inicial revelo las siguientes imperfecciones de origen:

Encoding inconsistente: el archivo viene en latin-1 con caracteres corruptos en acentos.**Formatos de fecha no estandar:** dd/mm/yyyy en lugar de ISO 8601.**Montos con comas separadoras de miles:** requieren normalizacion a tipo flotante.**Espacios multiples y mayusculas inconsistentes:** en nombres de proveedores y medicamentos.

Dado que todas las transacciones del dataset son del tipo *Adjudicacion Directa* y el origen de recursos es uniforme (*Recursos Federales Ramo 12*), se diseno una **variable target predictiva alternativa** con sentido de negocio: `target_costo_alto`, que clasifica como positiva (1) toda adquisicion cuyo monto total supere el **percentil 75** (\$466.81), permitiendo identificar compras anormalamente costosas para auditoria preventiva.

2. Mapeo de Procesos E-T-L (Pandas)

El pipeline de limpieza y transformacion se implemento en un notebook de Jupyter con Pandas, aplicando las siguientes reglas de negocio:

Regla	Implementacion Tecnica
Limpieza Regex	<code>str.replace(r\s+)</code> + eliminacion de caracteres no alfanumericos + homologacion a MAYUSCULAS
Normalizacion de fechas	<code>pd.to_datetime(format=%d/%m/%Y)</code> a tipo DATE ISO 8601
Tipado numerico	Conversion de comas a punto decimal con <code>float(str.replace)</code>
Variable target	<code>target_costo_alto = (total > p75).astype(int)</code> donde <code>p75 = \$466.81</code>
Surrogate Keys	Autoincrementales por dimension (sk) generadas con <code>range(1, n+1)</code>

3. Evidencias del Pipeline y Modelado (PostgreSQL 17)

Tras ejecutar el script DDL esquema_estrella_postgres.sql y el pipeline de carga carga_dimensiones_hechos.py, se verifico la creacion y poblacion de las 5 dimensiones y la tabla de hechos en el motor local PostgreSQL 17. Las siguientes capturas fueron obtenidas mediante consultas SQL en vivo al esquema ecbd_caso1.

Evidencia 1 - Creacion y Poblacion de Tablas

Conteo de registros por tabla del esquema estrella (consulta SELECT COUNT(*) en vivo).

Tabla	Registros
dim_tiempo	181
dim_medicamento	414
dim_proveedor	78
dim_institucion	2
dim_contratacion	19
fct_adquisiciones	2171

Motor: PostgreSQL 17 | Base: uteq_data_mining | Esquema: ecbd_caso1

Figura 1. Conteo de registros por tabla: las 6 tablas del esquema estrella estan creadas y pobladas (2,171 hechos).

Evidencia 2 - Estructura de la Tabla de Hechos

Definicion de columnas de ecbd_caso1.fct_adquisiciones (llaves foraneas + medidas + target).

Columna	Tipo de Dato	Restriccion
fact_id	bigint	NOT NULL
tiempo_sk	integer	NOT NULL
medicamento_sk	integer	NOT NULL
proveedor_sk	integer	NOT NULL
institucion_sk	integer	NOT NULL
contratacion_sk	integer	NOT NULL
cantidad	numeric	NOT NULL
precio_unitario	numeric	NOT NULL
total	numeric	NOT NULL
target_costo_alto	integer	NOT NULL

Motor: PostgreSQL 17 | Base: uteq_data_mining | Esquema: ecbd_caso1

Figura 2. Estructura de fct_adquisiciones: 5 llaves foraneas, 3 medidas numericas y el target binario, todas NOT NULL.

Evidencia 3 - Datos Poblados (JOIN Dimensional)

Top 12 adquisiciones por monto, uniendo la tabla de hechos con sus dimensiones.

ID	Fecha	Medicamento	Proveedor	Cant.	Total	Costo Alto
29	2025-01-06	PALIPERIDONA	JANSSEN-CILAG DE MXI	200.0	509280.0	1
30	2025-01-06	PALIPERIDONA	JANSSEN-CILAG DE MXI	200.0	509280.0	1
1187	2025-06-04	PALIPERIDONA	JANSSEN-CILAG DE MXI	200.0	509200.0	1
517	2025-04-03	PALIPERIDONA	JANSSEN-CILAG DE MXI	200.0	509200.0	1
518	2025-04-03	PALIPERIDONA	JANSSEN-CILAG DE MXI	134.0	341164.0	1
1211	2025-06-30	PALIPERIDONA	JANSSEN-CILAG DE MXI	133.0	338618.0	1
1919	2025-08-21	METILFENIDATO	PSICOFARMA SA DE CV	563.0	197798.79	1
241	2025-02-18	METILFENIDATO	PRODIFAM- S.A. DE C.	400.0	162904.0	1
519	2025-04-03	PALIPERIDONA	JANSSEN-CILAG DE MXI	50.0	127300.0	1
1188	2025-06-04	PALIPERIDONA	JANSSEN-CILAG DE MXI	50.0	127300.0	1
1915	2025-08-21	QUETIAPINA	INVESTIGACION FARMAC	443.0	125812.0	1
1618	2025-07-30	FLUOXETINA	LABORATORIOS SOLFRAN	8455.0	109915.0	1

Motor: PostgreSQL 17 | Base: uteq_data_mining | Esquema: ecbd_caso1

Figura 3. Muestra de datos poblados uniendo la tabla de hechos con sus dimensiones (Top 12 por monto total).

4. Validacion de Archivos Analiticos

El particionamiento Train/Test se genero con `train_test_split(..., test_size=0.25, stratify=y, random_state=42)`. La validacion confirma que la proporcion del target se conserva identica en ambos conjuntos:

Conjunto	Registros	Clase 0 (Costo normal)	Clase 1 (Costo alto)
Origen (100%)	2171	75.1%	24.9%
Entrenamiento (75%)	1628	75.1%	24.9%
Prueba (25%)	543	75.1%	24.9%

5. Esquema Estrella en PostgreSQL

El motor PostgreSQL 17 aloja el esquema `ecbd_caso1` con las siguientes características de diseño:

Llaves foraneas desde `fct_adquisiciones` hacia las 5 dimensiones. **Indices analiticos** sobre `tiempo_sk`, `medicamento_sk`, `proveedor_sk` y `contratacion_sk` para acelerar agregaciones. **Restricciones de dominio:** `CHECK (cantidad >= 0)`, `CHECK (target_costo_alto IN (0,1))`. **Columnas generadas:** `nombre_mes` derivado automaticamente del numero de mes.

6. Conclusion

La practica integral demostro la capacidad de procesar datos reales del Gobierno Federal con imperfecciones estructurales, aplicar limpieza avanzada con expresiones regulares, modelar dimensionalmente bajo el estandar Kimball y generar datasets balanceados para la fase posterior de mineria de datos. El target `target_costo_alto` ofrece un problema de clasificacion binaria realista (75/25) que servira como insumo para las unidades siguientes de Regresion Logistica, Arboles de Decision y Random Forest.